Kubernetes 节点故障处理手册

1 文档信息

本文档编号 OPS-K8S-040，版本 V2.4，密级内部公开，由基础架构部容器平台运维组编写并维护，适用于公司全部 Kubernetes 集群的节点级故障处置与计划内节点维护，覆盖生产、预发布两套环境的计算节点与承载控制面组件的 master 节点，边缘集群参照执行。本文档编写人为容器平台运维组赵鹏，审核人为基础架构部技术委员会与容器平台架构组联审，批准人为基础架构部负责人。本版本发布于 2026 年 3 月，自发布之日起 V2.3 版本自动作废，值班室张贴的处置卡同步更换。节点级操作影响面大，本手册的每一步都有明确的检查点与留痕要求，操作人跳步执行造成事故的按公司变更管理制度追责，手册本身没写清楚的地方不作为操作人免责理由，发现问题先反馈再继续。

修订记录说明如下。V2.0 版本把 NotReady 排查流程固化为三段式，并引入影响面确认先于登录节点的原则；V2.1 版本补充了证书到期续期的完整章节，收录了 2025 年 9 月某集群批量证书到期导致十六个节点同时掉线的事故；V2.2 版本重写计划内维护章节，明确封锁与腾空的顺序约束与数据核对要求；V2.3 版本增加节点替换时 StatefulSet 本地盘数据迁移的强制检查项；V2.4 版本补充节点恢复后的验证清单，并把节点代理组件日志的取证命令统一为标准用法。历次修订的评审纪要存于运维知识库，编号 OPS-K8S-040-CHANGELOG。本手册聚焦节点级故障，Pod 级的故障诊断与集群 DNS 的优化治理由兄弟文档承载，节点处置过程中发现的 Pod 侧问题转交对应值班，不要在节点手册的路径里顺手深挖。

2 概述

节点级故障的表现形态包括节点状态 NotReady、节点磁盘与内存压力触发的主动驱逐、节点证书失效导致的心跳中断、以及计划内维护窗口的节点摘除与回加。节点处置的通用原则有三条。第一条是影响面先行，任何节点处置动作开始前先确认受影响的业务清单，多节点同时故障优先怀疑网络与基础设施层，批量登录单机排查是错误方向；第二条是动作可回退，封锁节点有对应的解除封锁操作，腾空节点有重调度兜底，证书续期有前后的有效性核对，每个动作都要清楚它的逆操作是什么；第三条是留痕，kubectl 命令的执行记录与日志查看命令取证的日志片段都要贴回工单，事后审计与复盘依赖这些记录。本手册覆盖的命令行工具以 kubectl 与节点本地的 systemctl、日志检索命令、crictl 为主，所有命令在手册中给出标准形式，操作人按标准形式执行并记录输出。处置时效要求按节点角色分级。承载在线业务的 worker 节点 NotReady 的处置时限为十五分钟内定位根因、一小时内恢复或完成业务驱散；master 节点异常的处置时限压缩到五分钟内响应，三个 master 的集群单节点异常时集群控制面仍可用，但要立即评估其余两个节点的健康状况，防止连环掉线导致控制面丢失多数派。磁盘压力类故障的处置窗口相对宽松，但持续超过二十四小时的 DiskPressure 会反复触发驱逐，按隐患升级处理。所有节点处置动作的完成标准不是节点状态变绿，而是节点上的业务负载恢复到健康水位，这一点在验证章节展开。

3 节点 NotReady 排查流程

节点状态变为 NotReady 表示 kubelet 与控制面的心跳租约中断，控制面默认四十秒收不到节点心跳即标记 Unknown，再经过容忍时间窗口后该节点上的 Pod 会被驱逐。处置的第一步是确认影响面而不是登录节点，kubectl get nodes 看故障节点的数量与分布：单节点故障进入单机根因排

查；多节点同时 NotReady 优先怀疑网络与基础设施，控制面到节点网络的专线抖动、节点交换机故障、机架断电，这些因素在故障分布图上呈现出完全不同的聚集形态，按聚集形态先定位基础设施层再逐台确认。影响面确认的同时通知业务值班，如果故障节点上有承载关键服务的 Pod，先评估服务副本数是否还能撑住流量，副本数跌破下限的立即走应急扩容或者切流，业务止血永远优先于节点修复，这个优先级不允许颠倒。

影响面确认后登录故障节点做单机根因排查，排查按固定顺序执行三步。第一步 systemctl status kubelet 确认进程存活，进程挂了直接用 systemctl restart 把它拉起并回查退出原因，退出原因看 systemd 的单元日志；进程活着则进入第二步，用日志查看命令加时间参数回看最近十分钟的心跳相关报错，例如 journalctl -u kubelet --since "10 min ago" 是标准取证形式，报错信息会指向三类根因之一：容器运行时故障、内存耗尽、证书过期。第三步按报错指向的根因分支处理。容器运行时故障的典型表现是心跳报错里夹杂 containerd 连接失败字样，节点代理组件无法通过运行时汇报容器状态，处置是重启 containerd 后观察节点代理组件自动恢复；内存耗尽的典型表现是 dmesg 里出现 OOM 记录且节点代理组件的进程被内核杀掉过，处置是先清理异常进程释放内存再拉起节点代理组件，不清理直接拉起会再次被杀，治标不治本。

证书到期分支的表现最有辨识度：journalctl 的节点代理组件日志里有明显的证书校验失败字样，例如 x509 certificate has expired or is not yet valid 报错串，节点与控制面的认证握手失败导致心跳中断，节点状态在 NotReady 与 Ready 之间反复横跳的早期阶段之后彻底掉线。证书到期的完整处置流程在下一章单独展开，因为它的处置动作与检查点和其他根因完全不同，混在通用排查步骤里容易被漏掉前置检查。三类根因处置完都要回到验证环节：kubectl get nodes 确认节点 Ready、节点上的 Pod 恢复运行、业务指标回到基线，三样齐了才算单次处置闭环。排查全程的取证要求：日志查看命令与输出片段、systemctl 状态截图、dmesg 关键行，全部贴回工单，这些证据决定事后复盘的质量。

4 证书过期与续期

节点代理组件的客户端证书默认一年有效期，集群 CA 的根证书默认十年，公司多数集群由 kubeadm 部署，节点证书的续期依赖 kubeadm 的证书管理能力。证书过期的预防靠巡检：证书到期时间提前九十天进入告警，提前三十天列入必办清单，续期动作安排在维护窗口执行。已经发生过证书失效的处置流程如下，标准续期命令是 kubeadm certs renew 证书名，例如续期节点代理组件的客户端证书时把命令的证书名参数换成 client-cert，或者按实际证书清单逐个续期，master 节点上建议执行 kubeadm certs renew all 一次续齐全部组件证书，续期完成后必须用 systemctl 重启节点代理组件让新证书生效，该组件不会热加载证书。续期动作不需要重启节点，更不需要重装组件，这是很多新同学第一次遇到证书到期时的错误直觉，动辄重装节点的处置方式已经被历史事故证明是灾难放大器。

master 节点证书失效的处置有额外的顺序要求。三个 master 的集群如果全部证书到期，控制面 API 不可用，此时连 kubeadm 命令本身都可能因为连不上 API 而报错，正确姿势是先检查是否真的全部过期，个别 master 还能工作的先续它，用 kubeadm certs renew 完成后确认 API 恢复，再逐台处置其余节点；全部过期的极端场景需要按 kubeadm 文档的离线恢复流程先救活一个 API 再滚动续其余节点，这个流程敏感且步骤多，执行前必须拉容器平台架构组电话会审，不允许值班同学单独操作。2025 年 9 月的事故就是这个场景：某集群六个 master 因故未纳管续期巡检，

批量到期后值班同学试图逐台直接续期，其中一次证书续期命令在 API 不可用状态下报错后改用了重建命令，导致控制面组件配置被覆盖，故障从两小时拖成了十一个小时。事故后手册增加了本段的前置条件与升级要求。

续期后的验证有三个层次。证书层面，用 openssl 查看证书的起止时间已更新，kubeadm certs check-expiration 列出全部证书的剩余有效期，确认没有漏续的条目；节点层面，用日志查看命令回看单元日志，确认证书报错消失、心跳恢复正常，kubectl get nodes 确认节点回到 Ready；业务层面，节点上的 Pod 全部恢复且无重启风暴。验证通过后把续期记录登记进证书台账，台账记录节点名、续期时间、下次到期时间，台账数据同步给巡检系统做下一轮的提前告警。证书失效的根因追查同样重要：为什么巡检告警没有拦住，是告警通道失效还是节点未纳管，追查结论回写到巡检体系的改进项里，否则同样的过期还会再来一次。

5 计划内维护的标准动作

计划内维护的核心是把节点安全地摘出调度，标准动作序列有严格的先后顺序，顺序错了要么影响业务要么白做。第一步 kubectl cordon 节点名 把节点标记为不可调度，新的 Pod 不会再调度过来，这是先封路；第二步 kubectl drain 节点名 --ignore-daemonsets --delete-emptydir-data 驱逐存量 Pod，驱逐过程会遵守 PDB 的最小副本保护逐步进行，DaemonSet 的 Pod 被 --ignore-daemonsets 参数跳过，使用 emptyDir 本地存储的 Pod 需要 --delete-emptydir-data 参数才能被驱逐；第三步执行维护操作本身，例如内核升级、运行时升级、机器检修；第四步 kubectl uncordon 节点名 恢复调度，节点重新接单。四步之中封锁与腾空的顺序绝对不能反，先腾空后封锁的空档里调度器可能又把新 Pod 调上来，驱逐等于白做一遍，业务多抖一轮。

drain 之前的两个确认是本手册的强制检查项。第一个确认 PDB 配置存在且合理，腾空操作严格遵守 PDB，如果服务没有配 PDB，驱逐可能直接击穿最小副本数，业务瞬间掉容量；PDB 配了但 minAvailable 设得过高的服务会让腾空一直卡在等待，卡住超过十分钟要检查是 PDB 过严还是 Pod 终止卡壳。第二个确认 emptyDir 里没有不可丢的数据，--delete-emptydir-data 一旦执行，emptyDir 数据就没了，先登节点看一眼相关 Pod 的 emptyDir 用量与内容再下手，曾有业务把下载的中间文件堆在 emptyDir 里，一次腾空全部蒸发，事后才知道那是业务流程的中间态数据。两个确认完成后再执行腾空，执行过程盯住输出，每个 Pod 的驱逐结果都核对，卡住的按卡住原因分支处理。

维护完成后的回加动作是 uncordon，回加后的观察期要求不少于十五分钟。观察内容包括节点状态稳定在 Ready、新调度的 Pod 正常 Running、节点资源水位正常、无驱逐相关的残留事件。维护窗口的整体记录格式：封锁与腾空的执行时间、驱逐清单、维护操作内容、解除封锁时间、观察期结论，五段式记录贴回工单。紧急维护（节点已经半死需要立即处置）的场景允许跳过腾空直接关机维护，前提是业务侧确认副本数可承受，这类操作在工单里标注为应急路径并事后补记业务影响评估。计划内维护的时间窗口统一避开业务高峰，窗口申请提前一天在变更平台提交，审批人与值班班长两级确认。

6 节点恢复后的验证

节点恢复的验证不能只看 Ready 状态，Ready 只代表心跳恢复，节点上的业务是否真正健康需要分层核对。第一层是调度验证，kubectl describe node 看节点的可调度状态与资源分配量，解除封锁之后新 Pod 应该能正常落上来，验证方式是观察十分钟内的调度事件或者手动起一个验证 P

od；第二层是存量 Pod 验证，节点上全部 Pod 状态 Running 且重启计数不再增长，腾空后重调度回来的 Pod 要等业务就绪探针通过才算恢复；第三层是业务指标验证，节点承载的服务 QPS、延迟、错误率回到基线，这一层需要业务方接口人确认，DBA 或者业务值班在群里回一句确认即可闭环。三层验证通过后，节点处置工单才能关闭，只做了第一层就关单的属于流程违规。

节点级的残留检查容易漏。证书续期场景要复查 kubeadm certs check-expiration 的输出确认全部证书健康；运行时重启场景要抽查几个业务容器的日志无异常重连；网络组件场景要在节点上做一次到其他节点的连通验证。此外每次节点处置后要看一眼节点事件流，kubectl get events 按 node 过滤，确认没有驱逐失败、镜像拉取失败、挂载失败这类残留告警在持续产生。残留检查的耗时不超过五分钟，但能拦住相当比例的二次故障，历史数据上二次故障里有三成是残留问题没清干净导致的，这个数字足够说明五分钟值得花。

7 节点磁盘压力处置

节点 DiskPressure 条件为 True 时节点代理组件会主动驱逐 Pod 释放磁盘，被驱逐的 Pod 在其他节点重建，业务表现为实例漂移，频繁的 DiskPressure 等于业务在被动迁移。紧急处置按释放量从大到小排序三招。第一招清镜像，crictl rmi --prune 删除未使用的镜像层，通常能释放几十吉字节；第二招清退出的容器，crictl ps 配合过滤条件找出 exited 状态的容器逐个删除；第三招定位大文件，du 追查容器运行时目录、容器日志目录与 emptyDir 挂载点，找到吃盘的元凶再决定怎么处理。三招执行完 DiskPressure 解除的，仍要完成根因确认，否则下周同一节点再犯。需要强调磁盘压力的处置动作全部在节点本地执行，不涉及 Pod 级诊断，遇到特定 Pod 写爆磁盘的，定位到 Pod 之后把工单转给业务侧值班处理文件策略，节点侧只负责恢复节点健康。

根治措施在配置层。容器日志配最大尺寸与轮转份数，节点代理组件的容器日志参数在节点配置里固化，单容器日志上限建议一百兆、轮转五份；emptyDir 换成带配额的 PVC，让本地盘滥用有硬上限；镜像 GC 阈值调优，image-gc-high-threshold 设为 80 让清理在磁盘八成时启动，image-gc-low-threshold 设为 70 让清完留出余量，默认九十多才开始清理的配置在大镜像频繁变更的节点上太被动。DiskPressure 反复出现的节点说明磁盘容量与业务写入量已经不匹配，该加盘就加盘，靠反复人工清理维持的节点是定时炸弹，容量申请走基础设施的扩容流程，申请材料里附上磁盘增长曲线与清理记录，通过率会高很多。

8 节点替换与数据迁移

节点彻底报废走替换流程，流程四步。第一步导出旧节点的信息资产：kubectl get node 旧节点名 --show-labels 拿到标签与污点，记录节点角色与注册信息；第二步腾空节点并删除旧节点对象，腾空的操作按第五章标准动作执行，之后 kubectl delete node 把它从集群拓扑里移除；第三步新机器初始化后用相同主机名加入，kubeadm join 的 token 提前在控制面生成，token 默认两小时过期，生成后立即用或者用完再生成，加入后按导出值恢复标签与污点；第四步确认新节点 Ready 且调度量爬升到合理水位。云环境的节点替换配合集群自动伸缩组更简单：直接删除机器实例，伸缩组自动补一台新机器以相同配置加入集群，标签污点由节点初始化的配置管理工具自动恢复。

替换流程中必须核对的一项是 StatefulSet 的数据卷。本地盘场景需要人工把旧节点的数据迁移到新节点再挂载，跳过这一步，有状态服务在新节点上用空数据启动，对数据库类应用是毁灭性的：要么直接起不来报数据缺失，要么更糟，空数据被当成正常状态开始接收写入，旧数据与新写入

形成分裂脑。核对动作在 kubeadm join 完成后、解除封锁之前执行：列出该节点上原有 StatefulSet 的清单，逐个确认对应 PVC 的挂载状态，本地盘的确认数据已经迁移到位，网络存储的确认卷挂载正常。这一步是 V2.3 版本新增的强制检查项，起因是 2026 年 1 月的一次节点替换漏迁本地盘，MySQL 从节点用空目录启动后同步位点重置，主从链路重建花了一整夜。

9 预防性巡检与演练

节点层每周巡检的内容以段落形式说明。NotReady 历史事件清零核对，过去七天没有节点级掉线事件；全部节点 Ready 且节点代理组件版本一致，版本不一致的节点在大版本升级时会集体掉线，混版本窗口超过两周的列入整改；抽查节点代理组件的最近日志无周期性报错，重点看心跳、证书、运行时三类关键字；磁盘使用率低于百分之七十五，高于阈值的节点按第七章的容量流程处理；节点上的 Pod 数量与资源分配均衡，个别节点分配过热是调度倾斜的前兆，结合调度器的打分日志定位原因。证书与令牌每月核对一次：kubeadm certs check-expiration 在全部 master 与抽样 worker 上执行，节点代理组件证书与集群 CA 的到期时间提前九十天告警，续期动作安排在窗口期执行完毕；集群 join token 的管理台账同步更新，过期未清理的 token 及时删除。

演练每半年一次，演练内容为随机抽取一台业务节点做故障注入。注入方式为在节点上模拟心跳中断（停节点代理组件五分钟后恢复），验证内容有三项：Pod 驱散是否按 PDB 预期执行、服务容量在驱散期间是否守住底线、节点恢复后 Pod 是否正常回迁。演练报告归档并跟踪暴露问题的整改闭环，演练发现的典型问题包括 PDB 配置形同虚设、业务依赖单副本节点、emptyDir 滥用等，每项问题指定责任人与整改期限。演练时间选业务低峰，演练前通知全部业务值班，演练中服务指标跌破底线的立即中止并恢复，中止的演练择期重做，不追究中止责任，鼓励值班同学在演练里暴露问题而不是硬撑。

10 附录

操作速查以段落形式说明。查节点状态与影响面用 kubectl get nodes 配合 kubectl get pods 加 node-selector 过滤；登节点查节点代理组件用 systemctl status，回看最近日志用 journalctl 加 --since "10 min ago" 时间参数；证书核对用 kubeadm certs check-expiration，续期用证书续期命令加证书名或者 all 参数；计划内维护四步为封锁节点、腾空节点、维护、解除封锁，drain 的标准参数组合是 --ignore-daemonsets --delete-emptydir-data；磁盘清理三招为清镜像、清退出容器、du 定位大文件。节点处置工单的五段式记录模板在变更平台的工单模板库里，编号 OPS-K8S-040-FORM。

联系人与升级路径说明如下。容器平台运维组值班电话见值班系统，master 节点异常与批量节点掉线直接电话值班人与组长；容器平台架构组负责 kubeadm 离线恢复等高危流程的会审支持，响应时效两小时内，紧急场景电话拉人；业务接口人清单登记在集群的命名空间元数据里，腾空与节点替换前按清单通知。本手册修订建议提交文档维护人，季度末集中评审，涉及事故复盘结论的修订优先处理，高危流程章节的修订需要架构组会签后发布。