网络故障排查手册

1 文档信息

本文档编号 OPS-NET-050，版本 V2.0，密级内部公开，由基础架构部网络运维组编写并维护，适用于公司全部机房的服务器网络故障排查、跨机房链路质量分析与内核网络参数调优，覆盖生产环境物理机、虚拟机与容器宿主机，办公网终端的排查不在本手册范围内。本文档编写人为网络运维组周涛，审核人为基础架构部技术委员会与安全组联审（涉及内核参数与抓包合规条款），批准人为基础架构部负责人。本版本发布于 2026 年 1 月，自发布之日起 V1.9 版本自动作废。网络排查的结论直接影响故障定界与责任划分，本手册要求所有关键结论都有命令输出作为证据，口说无凭的定界结论在复盘会上不予采信，操作人要养成先取证后结论的习惯。

修订记录说明如下。V1.5 版本建立分层排查方法论，把物理层、网络层、传输层、应用层的验证顺序固化下来；V1.8 版本补充链路报文丢失定位章节，重点写清路径探测工具输出里中间跳分组遗失与真实丢失的区分方法；V1.9 版本增加 TCP 缓冲区与拥塞控制的调优章节，收录长肥管道场景的参数基线；V2.0 版本把跨机房专线排查独立成章，并新增抓包操作的合规要求与资源保护条款。历次修订的评审纪要存于运维知识库，编号 OPS-NET-050-CHANGELOG。应用侧的连接堆积缺陷这类问题的排查由兄弟文档承载，本手册不展开，遇到相关问题转应用运维值班处理，此类问题的根源在代码而非系统参数，这个方向在本手册里明确排除以免误导。

2 概述与分层排查方法论

网络故障排查遵循分层定位法：物理层、网络层、传输层、应用层逐层验证，先确认层再确认点，这个顺序不能乱。物理层看链路与网口，ethtool 网卡名确认 Link detected 为 yes，ip -s link 观察分组丢失与错误计数，网卡硬件层的错误计数只增不减说明链路本身有问题，换线换口换模块，链路层没确认就往上查是浪费时间；网络层看 IP 连通，ping 目标地址验证路由可达，路径探测工具定位报文遗失跳点；传输层看端口，nc -zv 目标 端口验证端口可达，ss -lntp 确认目标在监听；应用层看协议语义，curl -v 带详细信息请求，检查证书、头部与响应码。分层的价值是把模糊的服务不通拆解为可验证的断言，每一层的结论指导下一层往哪里看，跳层的排查等于撒网捕鱼，运气好捞到了也说不清为什么。

方法论之外还有三条纪律。第一条是对比原则：排查任何异常都要找对照，同机房其他机器、同业务其他实例、同目标其他路径，有对比才能把问题定位到独有因素上，单点看数据永远是猜；第二条是变更留痕：排查过程中做的任何环境改动（清缓存、改参数、重启进程）都要记录时间点，方便回退也方便把后续的新现象与改动关联；第三条是证据归档：关键命令的输出（路径探测报告、抓包文件、参数快照）随手存到工单附件，网络问题经常需要二次分析与跨团队对质，没有存档的输出等于白查。三条纪律看似繁琐，实际是缩短排查时间的最优路径，资深与资浅工程师在方法论上的差距往往不在工具使用而在纪律执行。

3 DNS 解析故障排查

DNS 问题的典型表现是 IP 直连正常而域名访问失败，这个特征本身就是最强的定位线索，看到它就直接进 DNS 排查路径，不要在四层模型里乱跳。排查第一步用 nslookup 域名看解析结果与使用的 DNS 服务器，nslookup 的输出前两行会显示当前生效的解析服务器地址，结果异常时先确认是所有域名都解析失败还是个别域名：全部失败查 DNS 服务本身与到 DNS 服务器的链路，个别失

败查该域名的权威记录与本地缓存。域名解析验证命令也可以显式指定解析服务器来区分路径问题，例如在域名后面直接跟上指定服务器地址的形式，能快速判断故障出在本地配置还是上游服务。dig 加加号详细参数是进阶替代，输出信息更全，但域名解析验证命令的默认输出更简洁，值班场景首选它，深入分析再换 dig。

第二步核对 /etc/resolv.conf 的配置，这是 DNS 故障排查里命中率最高的一步。resolv.conf 的 nameserver 条目决定了解析请求发往哪里，search 搜索域决定短主机名会拼上哪些后缀，配置错误占了 DNS 故障的大头：nameserver 指向已经下线的旧 DNS 服务器、search 域拼写错误导致短主机名解析到错误后缀、以及运维手工改过域名解析配置文件后被配置管理工具回滚造成的配置漂移。核对时拿机房标准配置模板逐行比对，容器与 Kubernetes 环境还要额外注意 ndots 配置，ndots 默认值会让带点的短名先走搜索域多次重试再走绝对查询，解析耗时被放大好几倍，这是容器环境 DNS 慢的经典原因，调优它属于集群 DNS 治理范畴，本手册只提示现象与排查入口。

第三步区分本地缓存问题与上游问题。systemd-resolved 的缓存用 resolvectl flush-caches 清理后重试，清理后恢复说明是缓存了过期记录，继续追过期记录为什么会进来，通常是 DNS 服务器侧的记录更新后 TTL 内的旧值仍被缓存层持有；清理后不恢复说明问题在上游或者链路，回到第二步确认 nameserver 可达性。第四步检查应用层的长连接缓存：应用的连接池里躺在旧 IP 上的存量连接不会跟随 DNS 更新，表现为改了 DNS 部分流量还走老地址，重启应用才能彻底恢复，这类问题严格说不是 DNS 故障而是应用设计缺陷，但现象上经常被误报为 DNS 不生效，排查到这一步可以定界转交应用侧。DNS 故障的证据要求：nslookup 的完整输出、resolv.conf 的当前内容、清理缓存前后的对比结果，三样齐全才允许出结论。

4 链路丢包定位

丢包定位的核心工具是 mtr，它结合了 traceroute 的路径发现与 ping 的持续探测，标准探测形式为 mtr -Tzwb 目标IP，参数含义依次是 TCP 模式、显示压缩地址、同时显示 ping 与 TCP 探测、报告模式。该工具的 Loss% 列按跳点显示分组遗失率，解读时最重要的一个知识点是：中间节点的报文遗失可能是路由器对 ICMP 限速的假象，路由器控制平面忙着转发无暇响应探测包，表现为中间某一跳遗失率百分之几十但后续跳正常；只有最终目标跳出现的报文丢失才是真实的分组遗失，把中间跳的分组遗失当成故障会走大量弯路，这是 V1.8 版本单独写进来的高频误判。判断方法看两点：中间跳有报文遗失但后续跳恢复正常的属于限速假象，分组丢失从某一跳开始一直延续到末端的才是真实故障，真实分组遗失的起点跳就是故障段的上边界。

确认真实的分组遗失后看丢在哪一段。同机房内的报文遗失查交换机与网卡：ethtool -S 网卡名的 rx_dropped 与 tx_dropped 计数是硬件层的证据，计数增长说明分组丢失发生在本机网卡的收发队列，常见原因有网卡队列打满、缓冲区不足、速率双工不匹配，交换机侧要看端口计数器的错误包统计，需要网络组配合登设备查询；跨机房的报文遗失查专线与运营商链路，报障时提供路径探测工具的完整输出能显著缩短扯皮时间，两端各自发起的链路质量探测报告放在一起能圈定故障段。TCP 层面的重传观察用 ss -ti 加 -n 输出的 retrans 计数与 nstat 的 TcpRetransSegs 增速，重传率超过百分之一即明显影响吞吐，超过百分之五业务基本不可用，这两个阈值写进监控告警基线。分组遗失类故障的处置时限：核心链路丢包率超过百分之一的十五分钟内报障，专线供应商的 SLA 约定按合同条款执行赔付流程。

分组遗失排查还有两个进阶场景。软中断单核打满的场景：mpstat -P ALL 1 观察某个 CPU 的百分之 soft 飙高接近满值，单核处理全部网络中断是万兆网卡的经典瓶颈，处置是用网卡多队列与 RPS 配置把软中断分散到多核，配置固化到系统的网络初始化脚本里；突发报文遗失的场景：平均遗失率不高但业务周期性抖动，用更长周期的路径探测报告模式抓现场，配合 ss 的重传计数时间线对齐业务抖动的时间点，能锁定报文丢失与特定业务流量的相关性，这类问题的根因经常是某台设备的队列在流量突发时溢出，属于容量问题不是故障问题，定性结论直接影响后续是修设备还是扩容量。

5 TCP 缓冲区调优

吞吐上不去而 CPU 空闲时通常是缓冲区与窗口问题，这类问题的特征是资源明明有余就是跑不快，应用日志无报错、CPU 使用率低、但传输速率卡在一个明显低于带宽的数值上。核心参数是 net.core.rmem_max 与 net.core.wmem_max，它们定义了内核收发缓冲区的最大值上限，默认值通常只有两百多K，对高带宽长延迟的链路远远不够。调优时把 net.core.rmem_max 与 wmem_max 调大到 16MB，同时把 net.ipv4.tcp_rmem 与 net.ipv4.tcp_wmem 的自动调节区间同步放宽，tcp_rmem 的三个值分别是最小、默认、最大，最大值不能超过接收缓冲区上限参数的设定，超过的部分不生效，这是调参时最常见的低级错误：只调了自动调节区间没调上限，或者只调了上限没调区间，两边不配套等于白调。

长肥管道场景是缓冲区调优的主要受益方。带宽时延乘积决定了一条链路在跑满前需要多大的在途数据量，跨洲链路一百五十毫秒延迟乘以一吉带宽，需要的窗口超过十六兆字节，默认缓冲区在这个场景下直接把吞吐上限压死在几兆每秒，现象是跨机房传文件慢得离谱而本地正常。调优接收缓冲区上限参数与 tcp_rmem 之后，配合第八章的 sysctl 固化流程，跨洲链路的传输速率通常能提升一个数量级。需要提醒的是缓冲区调大是有代价的，单连接的内存占用上限变大，高并发短连接的服务器盲目调大接收缓冲区上限会放大内存压力，内存水位高的机器先评估再改，调优参数按业务类型分级设定，批量传输型节点与高并发接入型节点的参数表在基础设施配置库里分开维护。

验证缓冲区调优效果的方法：ss -ti 加 -n 看具体连接的 send_rate 与未确认数据量，调优前后对比同一条链路的实际速率；iperf3 打点到目标机房测极限带宽，排除应用层因素的干扰；长肥管道的验证必须用真实跨机房路径，本机回环测试验证不了窗口问题。调优生效的判定标准是速率逼近链路带宽的百分之九十以上且重传率低于千分之五，达不到的继续按分组遗失章节排查链路质量，缓冲区与链路质量两类问题经常叠加出现，调优顺序是先治报文遗失再调窗口，报文遗失没治好调窗口的收益会被重传吃掉大半。

6 bbr 拥塞控制启用

拥塞控制算法决定发送端在报文遗失与延迟信号面前如何调节速率，默认的 cubic 算法基于分组丢失信号降速，在有一定随机遗失率的共享链路上表现不佳，一次随机的非拥塞报文丢失就会让速率腰斩再缓慢爬升。高延迟链路建议启用 bbr 替代默认 cubic，该拥塞控制算法的优势在于不依赖分组丢失信号，它基于带宽与延迟的实测估计来调节发送速率，在随机遗失率百分之一的链路上依然能维持发送速率，长距离传输的吞吐经常翻倍。启用方法是设置 net.ipv4.tcp_congestion_control 为 bbr，一行 sysctl 配置就能生效，前提是内核版本支持且对应内核模块已加载，内核四点九以上的版本原生支持，公司标准内核镜像全部满足，个别老旧自定义内核需要先确认模块存在。

该拥塞控制算法的启用流程与回退方案如下。第一步确认现状，sysctl net.ipv4.tcp_congestion_control 查看当前算法，sysctl net.ipv4.tcp_available_congestion_control 确认可用列表里存在目标算法，没有的先加载对应的内核模块；第二步按前述方法设置 net.ipv4.tcp_congestion_control 并立即生效，观察业务指标一小时；第三步固化到 sysctl 配置文件防止重启失效；第四步灰度推广，按机房分批启用，每批观察一天。回退方案就是把参数改回 cubic，改回后立即生效无需重启，回退触发的条件是启用后出现异常的重传增长或者业务侧报告新的网络问题，虽然新算法与 cubic 的兼容性问题很少见，回退通道必须在启用前就验证通畅，没有验证过回退的变更不允许上生产。

该拥塞控制算法的适用边界要说明清楚。收益最大的是长肥管道与有随机报文遗失的链路，跨机房同步、异地备份、跨国访问这类场景；短距离低延迟的内网链路收益不明显，内网瓶颈通常在应用层与中断处理，换该算法属于无效操作；对极端要求低延迟的交互型业务，新算法与 cubic 的取舍要做对比测试，个别场景 cubic 的延迟抖动反而更小。拥塞控制与缓冲区调优是配合关系，第五章的接收缓冲区上限参数调大给该算法的持续发送提供了缓冲空间，两者一起上才能吃满长肥管道的带宽，单独启用任何一项收益都打折。全部内核参数变更必须写入 sysctl 配置文件并经基础设施配置库统一下发，手工在机器上改的参数重启即失效，等于给下一次故障埋雷，配置库的参数版本化记录也是审计的依据。

7 跨机房专线排查

跨机房专线的故障形态包括链路中断、质量劣化（分组遗失、延迟升高、抖动）与带宽跑满，排查的前提是知道正常基线：每条专线在监控平台有延迟、报文遗失率、带宽利用率的常态曲线，排查时先看曲线偏离基线的形态再动手，没有基线意识的排查都是在重新发明轮子。链路中断的处置流程：确认中断影响的应用清单，触发多线自动切换的确认切换是否完成，未自动切换的按预案手工切到备用线路，切流动作十分钟内完成，切流后的业务验证按应用清单逐项确认，然后才轮到供应商报障与修线，业务优先抢通永远是第一位的，修线是供应商的事，值班同学不要陷入修线细节而忽略了业务面的确认。

质量劣化的排查用双向路径探测圈定故障段。从两端机房各自向对方按第四章的标准参数发起路径探测，两份报告对照看报文遗失起点：A 到 B 方向从某一跳开始出现报文丢失而 B 到 A 方向正常，问题大概率在单向链路上；两个方向在同一跳附近劣化的，问题在中间共用段或者目标侧。圈定故障段后对照专线拓扑图定位承载设备与运营商区间，向供应商报障时附上两份路径探测报告、故障起止时间、分组遗失率与延迟数据，数据齐全的报障处理速度明显快于只说网络慢的报障。带宽跑满的排查先区分业务性与异常性：业务性跑满是真实流量增长，走扩容流程并同步评估压缩与限速方案；异常性跑满要抓包定位流量构成，异常流量里最高频的是备份任务窗口失控与某个应用的重传风暴，前者调度到低峰限速，后者按分组遗失章节的路径查链路质量。

专线排查的协作纪律。跨机房问题涉及两端机房的本地团队与网络组，定界结论出来前各自先完成本地侧的自查（本端网卡计数、本端交换机端口、本端路径探测结果），自查结论汇总到故障群再联合定界，避免互相等待；报障与升级的时限：质量劣化持续三十分钟未定位的报障供应商，两小时未恢复的升级到组长拉供应商联席会；每次专线故障的复盘要回写专线的监控基线与预案，特别是切流预案里过时的应用清单，两次故障之间业务接入清单变更是常态，预案不更新的切流在真实故障时会漏掉新业务。

8 抓包操作与合规要求

tcpdump 是网络排查的终极武器，用好事半功倍，用不好把生产机器磁盘抓爆，因此本手册对抓包操作设置资源保护条款。过滤器要精确：host 加 IP 限定端点，and port 加端口限定服务，not port 22 排除自身 SSH 流量避免把远程终端卡死，过滤条件越精确抓包文件越小，线上高流量机器务必收窄条件，万兆网卡上无过滤的全量抓包几秒钟就是几个吉字节，磁盘被抓包文件打满引发的次生故障比原故障更严重。抓包写文件用 -w 落盘，加 -C 限制单文件大小、-W 限制文件份数形成滚动覆盖，机器上滞留的抓包文件排查完立即清理，清理动作列入故障处置的收尾清单。分析用 Wireshark 打开落盘文件做离线分析，肉眼在线看 tcpdump 只适合低流量场景。

抓包的合规要求由安全组联审后写入手册。生产网络抓包可能接触到业务数据明文，抓包操作必须挂故障工单执行，工单号写进操作记录；抓包文件不得传出公司内网分析环境，涉及敏感业务（支付、用户隐私数据）的抓包文件用完即销毁并向安全组备案销毁记录；对外提供的抓包样本必须先做脱敏处理。RST 来源的判断技巧：看 RST 包的 TTL 是否与该流正常包一致，一致的 RST 来自对端，不一致的来自中间设备劫持，定位运营商旁路干扰时屡试不爽。重传风暴的定位在 Wireshark 的专家信息里看 Retransmission 分组统计，按流聚合找出重传最多的连接，再回到 ss -ti 的连接详情看该流的重传计数与速率，两个视角互相印证后出结论。

全部调优与排查命令的基线快照要求：每次网络类故障处置完成后，把当时的参数快照（sysctl 网络相关全量输出、网卡队列配置、路由表）存档到工单，这些快照在后续同类故障时是最好的对照基线。工具与联系人说明如下：路径探测工具、域名解析验证命令、ss、tcpdump 全部使用系统自带版本，Wireshark 分析机统一装在运维跳板机上，版本由工具组维护；网络运维组值班电话见值班系统，跨机房专线故障直接打值班与组长，供应商接口人的通讯录在专线台账的首页；本手册修订建议提交文档维护人，季度末集中评审，内核参数基线的修订需要安全组会签。